

# Poskus razlikovanja umetnostnih obdobj v slikarski zbirki WikiArt z računalniško zaznavo izbranih likovnoteoretskih konceptov

Julija Bučar, Rok Likar, Hana Skitek, Jana Volk, Narvika Bovcon

Fakulteta za računalništvo in informatiko, Univerza v Ljubljani, Večna pot 113, 1000 Ljubljana  
E-pošta: jb2662@student.uni-lj.si, rl2153@student.uni-lj.si, hs8668@student.uni-lj.si,  
jv0719@student.uni-lj.si, narvika.bovcon@fri.uni-lj.si

## An attempt to differentiate art periods in the WikiArt painting collection based on the detection of selected art-theoretical concepts

**Abstract.** *This article discusses the integration of computer vision techniques in analyzing large digital art collections, specifically focusing on the WikiArt database. The study aims to explore visual attributes of artworks across different art periods using various algorithms. Key analyses include edge density, color palettes, emotional responses, brightness and saturation, and compositional techniques.*

*Edge density is analyzed using the Canny edge detection algorithm, revealing significant differences in complexity among art styles, with Neo-Impressionism showing the highest density. Color palette analysis through k-means clustering, however, indicates discrepancies between expected and actual results, likely due to dataset limitations. Emotional responses are examined using data from the ArtEmis project, highlighting prevalent positive emotions in art descriptions like contentment and awe.*

*Brightness and saturation trends are visualized with ImagePlot, showing varying patterns across periods. Finally, compositional techniques are assessed with saliency maps and classical composition rules, demonstrating diverse adherence to these rules across different eras. The findings provide insights into the visual and emotional diversity of art across periods and suggest improvements for future analysis methods.*

## 1 Uvod

Analiza velikih slikarskih zbirk z računalniškim vidom je postala pomembno raziskovalno področje, ki združuje umetnost in tehnologijo [1]. Računalniški vid omogoča raziskovalcem, da analizirajo vizualne lastnosti umetniških del na način, ki je bil prej nemogoč [2][3][4][5]. Projekt Google Arts & Culture [6] je na primer izvedel več eksperimentov, kjer so uporabili računalniški vid za vizualizacijo analiz umetniških del, kot so iskanje podobnih umetnin, prepoznavanje obrazov in slogov ter celo ustvarjanje novih umetniških del na podlagi obstoječih stilov. Takšni projekti izboljšujejo dostopnost umetnosti, in omogočajo nove načine interakcije z umetnostjo.

Lev Manovich, eden izmed najvplivnejših teoretikov digitalne kulture [7], je s svojim delom na področju kulturne

analitike in vizualizacije podatkov prispeval k razvoju metod za analizo velikih zbirk vizualnih podatkov. Njegova raziskava pokaže, kako lahko digitalna orodja in metode pripomorejo k boljšemu razumevanju kulturnih artefaktov [8].

V tem članku smo se osredotočili na analizo slikarske zbirke WikiArt [9], kjer smo raziskovali različne vidike umetniških del v umetnostnozgodovinskih obdobjih, ko prihaja do spremembe v obdelavi površine upodobljenih motivov, in sicer od gladke površine k razčlenjeni upodobitvi z ločenimi barvnimi potezami. Izbrali smo obdobja: barok, rokoko, neoklasicizem, romantika, realizem, pre-rafaeliti, impresionizem, neoimpresionizem, nadrealizem. Zanimalo nas je, kako se v slikarskih delih omenjenih umetniških obdobj odražajo nekateri ključni likovnoteoretski koncepti, kot so: barvne palete, barvna nasičenost in svetlost, tekstura (gostota robov) in kompozicijske mreže. Nazadnje nas je zanimalo, ali lahko z rezultati izbranih metod računalniške analize ločimo umetnostnozgodovinska obdobja, kot so predstavljena z deli v zbirki WikiArt. S pomočjo različnih metod in algoritmov smo poskušali odgovoriti na vprašanja: 1. Kakšna je gostota robov v slikah različnih umetniških obdobj? 2. Kako se barvne palete razlikujejo med obdobji? 3. Kako se svetlost in nasičenost slik spreminjata glede na umetniška obdobja? 4. Katere kompozicijske tehnike so najbolj značilne za posamezna umetniška obdobja? 5. Kakšni so čustveni odzivi gledalcev na umetniška dela iz različnih obdobj?

## 2 Analiza slikarskih del

### 2.1 Kakšna je gostota robov v slikah različnih umetniških obdobj?

Za vsako obdobje smo analizirali gostoto robov v slikah. Uporabili smo Canny edge detection algoritem [10]. Gostota robov je bila izračunana kot razmerje med številom pikslov, ki tvorijo robove, in celotnim številom pikslov v sliki. Slike so bile prebrane in pretvorjene v sivinsko obliko (grayscale) z uporabo funkcije cv.imread iz knjižnice OpenCV 4.10.0, da bi odstranili barvne informacije in se osredotočili le na robove. Delali smo z že prevedeno različico knjižnice OpenCV, ki je bila nameščena prek pip iz uradnega Python Package Indexa (PyPI) na operacijskem sistemu Windows 11. Uporabljen je bil Cannyjev algoritem z dvema pragovima (100 in 200), kar omogoča zaznavanje robov na podlagi sprememb inten-

živnosti. Algoritem identificira piksele, kjer so spremembe dovolj izrazite, da predstavljajo rob (slika 1). Za vsako umetniško obdobje smo izračunali povprečno gostoto robov na podlagi rezultatov vseh analiziranih slik.

Analiza povprečne gostote robov razkriva različne stopnje podrobnosti in kompleksnosti med umetniškimi slogi. Neoimpresionizem izstopa z najvišjo gostoto robov 17%, kar ustreza številnim majhnim pikam, ki ustvarjajo visoko kompleksnost. Prerafaelitska bratovščina 12%, impresionizem 11% in nadrealizem 10% prav tako kažejo relativno visoko gostoto robov, kar odraža bogate podrobnosti. Srednje vrednosti gostote robov se pojavljajo pri baroku 9%, realizmu 9% in romantiki 9%, ki uravnovežijo podrobnosti z jasnimi linijami. Nižje vrednosti so prisotne pri neoklasicizmu 6% in rokokoju 6%, kjer prevladujejo jasne oblike in ploskovita ozadja (npr. nebo ali stene).

Medtem ko je Cannyjev algoritem zelo učinkovit pri zaznavanju robov in strukture slike, ima tudi svoje omejitve. Algoritem ne more natančno zaznati specifičnih potez čopiča, ki so lahko značilne za določena umetniška obdobja.



Slika 1: Rembrandt van Rijn, *The Night Watch*, 1642 (levo) in detekcija robov na sliki (desno).

## 2.2 Kako se barvne palete razlikujejo med obdobji?

Analizo barv smo izvedli z metodo gručenja (k-means clustering). To je algoritem, ki se uporablja pri nenadzorovanem strojnem učenju za razvrščanje podatkov v skupine (clustre). V našem primeru smo algoritem uporabili za razvrščanje slik posameznih obdobji na barvni spekter.

Izvirna koda je bila pridobljena iz github repozitorija omilab/image-color-analysis [11], [12]. Kodo smo rahlo prilagodili za naše potrebe, deluje po spodaj opisanem postopku. Uporabili smo programski jezik Python 3.11.2 in knjižnice Pillow 10.1.0, scikit-learn 1.4.1.post1, numpy 1.23.5 in vgrajena modula time in os.

Skripti najprej podamo pot do datoteke s slikami, nato pa koda generira vertikalni kolaž (kot sliko RGBA) iz vseh podanih slik. Nato se kolaž pretvori v tabelo tipa np.array, katero sploščimo in iz nje odstranimo vse prozorne piksele (kjer so R, G, B in A vrednosti enake nič). Nazadnje ustvarimo objekt tipa KMeans (iz modula sklearn.cluster) z izbranim številom gručenj (angl. cluster), v našem primeru deset. Objektu podamo prej omenjeno tabelo. Iz modela nato pridobimo število pikslov v vsaki izmed gručenj, iz katerih lahko izračunamo delež vsake barve. V našem primeru koda generira novo sliko desetih stolpcev, ki prikazujejo razmerja najpogostejših barv.

Pomembno je poudariti, da z algoritmom nismo dobili pričakovanih rezultatov. Za primer lahko vzamemo obdobje rokoko, za katerega je značilna slika *The Swing* (1767) avtorja Jean-Honoréja Fragonarda, pričakovana barvna paleta pa vsebuje odtenke roza barve (#D98677, #C27670), zelene (#657A65, #667367, #98A78B) in odtenke modre (#465766, #7196AF, #5D6B6C). Ta paleta se precej razlikuje od barvne palete, pridobljene z zgoraj opisanim algoritmom. Dobili smo namreč temnejše barve in zelo podobne paleti iz obdobja baroka, ki pa naj bi vsebovala predvsem črne in rjave barve (#201E1C, #BFA98E, #7A5A44, #4E3A2C) s temno modrimi in rdečimi poudarki (#30436C, #A83F32). Prav tako je pridobljena paleta podobna impresionistični, čeprav bi ta morala vsebovati svetlejšje barve, kot so viola (#BE5299), rumena (#BCAE46), zelena (#3A6D47) oranžna (#FF991C) in bela (#FFFFFF). Iz tega sklepamo, da se značilne barve v zbirki slik WikiArt pri posameznih obdobjih slabo izražajo, najverjetneje zaradi obsežnosti zbirke in raznolikosti del različnih avtorjev, ki v posameznem obdobju segajo skozi celoten razvoj sloga od zgodnjih zametkov do najbolj značilnih primerkov. Iz tega sklepamo, da ozek izbor reprezentativnih del, ki je bil z metodo "natančnega gledanja" uvrščen v umetnostnozgodovinski kanon in je osnova za razlikovanje slogovnih obdobji, ne sovпада s širšim naborom del, ki jih lahko pregledujemo na način "oddaljenega gledanja" s pomočjo računalniških algoritmov.

## 2.3 Kako se svetlost in nasičenost slik spreminjata glede na umetniška obdobja?

Za vizualizacijo svetlosti in nasičenosti (slika 2) smo uporabili ImagePlot [13], brezplačno orodje, ki omogoča vizualizacijo zbirk slik ali videov. Deluje s programom ImageJ, ki je namenjen obdelavi slik. Namesto da bi podatke prikazovali kot točke, črte ali stolpce, ImagePlot prikaže dejanske slike.

Stilski prostor [14] je koncept, ki nam pomaga razumeti in primerjati različne vizualne slogove umetniških del. Vsako sliko lahko opišemo s številnimi vizualnimi lastnostmi. Na 2-D grafu prikazujemo dve izbrani lastnosti, vsako na svoji osi. Tako sestavimo graf za obravnavano obdobje glede na izbrani lastnosti, razporeditev točk na grafu nato primerjamo z razporeditvijo točk na grafu iz drugega obdobja.

Za našo analizo smo se osredotočili na svetlost in nasičenost slik. Naredili smo datoteko z metapodatki in vanjo zapisali imena posameznih slik, ter za vsako sliko podatke o procentu svetlosti in povprečni nasičenosti slike. Slike smo obdelali z uporabo knjižnice OpenCV 4.10.0. Uporabili smo že prevedeno različico knjižnice OpenCV, ki je bila nameščena prek pip iz uradnega Python Package Indexa (PyPI) na operacijskem sistemu Windows 11. Najprej smo za vsako sliko določili svetlost z uporabo sivinskih vrednosti, ki jih OpenCV izračuna pri pretvorbi slike v sivinsko lestvico. Za določitev svetlih in temnih pikslov smo uporabili prag 127 na sivinski lestvici (od 0 do 255), pri čemer smo svetlost slike izračunali kot delež svetlih pikslov v primerjavi s celotnim številom pikslov na sliki. Za izračun povprečne nasičenosti smo najprej

vsako sliko prebrali v RGB barvnem prostoru s pomočjo knjižnice OpenCV 4.10.0. Nato smo slike pretvorili v HSV (Hue, Saturation, Value) barvni prostor, ki omogoča ločeno obravnavo barvnega odtenka, nasičenosti in svetlosti. Pretvorbo smo izvedli s funkcijo `cv2.cvtColor`, ki sliko pretvori iz RGB v HSV format. V HSV formatu smo se osredotočili na kanal nasičenosti (S), ki vsebuje informacije o intenzivnosti barve. Program je glede na te podatke potem razvrstil slike in naredil vizualizacijo (slika 2). Na X osi grafikona je svetlost (slike gredo z leve proti desni od najtemnejših do najsvetlejših), na Y osi pa nasičenost (od spodaj navzgor od najmanj nasičenih slik do najbolj nasičenih).

V zgornji vrsti grafikonov so slike obdobja barok, rokoko in neoklasicizem. Pri vseh treh obdobjih je opazen velik delež slik na levi strani grafikona (to so slike z nizko vrednostjo svetlosti). Presenetilo nas je, da je tudi v rokoku veliko temnih slik, saj to obdobje povezujemo z lahkotnejšimi temami in svetlejšimi barvami (npr. dela Tiepola). Sklepamo, da so kot temni zaznani predvsem številni portreti iz tega obdobja. Svetlost slik se povečuje, ko gremo od baroka proti neoklasicizmu. Vsa tri obdobja imajo srednjo nasičenost, najvišjo med njimi ima rokoko.


V srednji vrsti grafikonov so slike obdobja romantike, realizma in preraphaelitov. Romantične slike vsebujejo širok razpon svetlosti, kar poudarja čustveno razpoloženje. Realistične slike imajo bolj naravne in manj nasičene barve, s čimer dosežejo čim bolj pristen prikaz resničnosti. Pri obdobju preraphaelitov opazimo, da je večina slik v sredini X osi, torej niso pretirano temne niti svetle. Ker so preraphaeliti stremeli k živahnemu upodabljanju narave, imajo visoko nasičenost.

V zadnji vrsti grafikonov so slike obdobja impresionizem, neoimpresionizem in nadrealizem. Impresionistične slike imajo pogosto svetle barve, ki so tudi visoko nasičene. Neoimpresionizem ima najbolj svetle slike in tudi najmanj nasičene. Pri nadrealističnih slikah opazimo večji delež svetlih slik, ki so bolj nasičene od neoimpresionističnih. Nadrealizem, ki stremi k upodabljanju podzavestnih in sanjskih prizorov, pogosto uporablja svetle in živahne barve.

Tudi pri analizi barvne nasičenosti in svetlosti slik po slogovnih obdobjih nismo dobili izrazito različnih rezultatov, kot bi pričakovali, če primerjamo samo najbolj reprezentativna dela posameznih obdobja ali pa samo izbrane avtorje.


## 2.4 Katere kompozicijske tehnike so najbolj značilne za posamezna umetniška obdobja?

Za analizo kompozicij slikarskih del smo uporabili t. i. zemljevid opaznosti (angl. saliency maps) (slika 3). To so vizualni prikazi, ki omogočajo identifikacijo območij slike, ki pritegnejo največ pozornosti gledalca. Uporabljajo se za analizo in razumevanje, kako pozornost gledalca potuje skozi vizualne elemente. Naredili smo program, ki za vsako sliko ustvari zemljevid opaznosti s pomočjo Saliency API-ja, ki ga ponuja knjižnica OpenCV [15]. Pri tem smo uporabili naslednjo programsko opremo in knjižnice: Python verzija 3.12, skupaj z naslednjimi knjižnicami: Matplotlib 3.9.0, NumPy 1.26.4, OpenCV 4.10.0, skimage



Slika 2: Vizualizacija svetlosti in nasičenosti slik po posameznih slogovnih obdobjih. Vsak kvadrat je grafikon za eno slogovno obdobje, v zgornji vrsti si sledijo z leve proti desni barok, rokoko, neoklasicizem, v srednji vrsti romantika, realizem, preraphaeliti, v spodnji vrsti impresionizem, neoimpresionizem, nadrealizem. Točke na grafikonu so posamezne slike, njihova pozicija na grafikonu je določena na osi x z odstotkom svetlih barv na sliki (svetlost narašča od leve proti desni) in na osi y s povprečno nasičenostjo barv na sliki (nasičenost narašča od spodaj navzgor).

0.24.0, in SciPy 1.13.1. Vse knjižnice so bile pridobljene iz uradnih distribucij in niso bile ročno prevedene. Program smo izvajali v sistemskem okolju Windows.




Slika 3: Peter Paul Rubens, *Exchange of The Two Princesses of France and Spain*, 1615 (levo) in zemljevid opaznosti (desno). Zemljevid prikazuje območja slike, ki pritegnejo največ pozornosti gledalca, določena s pomočjo Saliency API-ja iz knjižnice OpenCV. Z elipsami so označena presečišča zlatorezne mreže.

Algoritem smo zasnovali tako, da na podlagi zemljevidov opaznosti preverja prisotnost petih klasičnih pravil kompozicije: pravilo tretjin, zlati rez, diagonalna kompozicija, centralna kompozicija in rabatment (kvadrata z diagonalami nad krajšima stranicama pravokotne slike). Vsakemu slikarskemu delu je dodeljena vrednost, ki izraža odstotek prisotnosti posameznega kompozicijskega pravila.

Pravilo tretjin preverjamo tako, da na sliki določimo presečišča črt, ki sliko delijo na tretjine po vertikali in po horizontali, in preverimo, ali se večina pomembnih delov slike nahaja na teh območjih. Za zlati rez ustvarimo zlato-rezno mrežo in preverimo, ali se ključni deli slike nahajajo na presečiščih. Pri preverjanju diagonalne kompozicije najprej s Cannyjevim algoritmom [10] določimo robove v sliki, nato s pomočjo algoritma Hough Line Transform [16] poiščemo ravne črte. Za vsako najdeno črto preverimo, ali je diagonalna (njen kot je med 30 ali med 120 in 150 stopinjami). Če je najdeno dovolj diagonalnih črt, slika velja za diagonalno kompozicijo. Pri centralni kompoziciji določimo središče slike in preverimo, ali se pomembni deli nahajajo v tem območju. Pri preverjanju prisotnosti pravila rabatment določimo položaj desne stranice levega kvadrata in leve stranice desnega kvadrata ter preverimo, ali se ključni deli slike nahajajo ob teh stranicah.

Rezultati analize (slika 4) kažejo, da se pravilo tretjin pogosto pojavlja v vseh obdobjih, še posebej izrazito v rokokuju (70%) in neoklasicizmu (68%). Zlati rez je prav tako relativno pogost, z najvišjo prisotnostjo v rokokuju (64%) in neoklasicizmu (60%). Diagonalne kompozicije so najbolj izražene pri preraphaelitih (35%) in nadrealizmu (27%). Centralna kompozicija se pojavlja z zmerno pogostostjo, pri čemer je najizrazitejša pri rokokuju (47%) in neoklasicizmu (41%). Rabatment je močno prisoten v vseh obdobjih, najizrazitejši pa je v obdobjih od romantike (65%) do neoimpresionizma (62%), kar kaže na to, da so te slike pogosto uporabljale robove za kompozicijsko ravnovesje. Skupno gledano, rezultati razkrivajo raznolike pristope k uporabi kompozicijskih pravil skozi različna umetniška obdobja, pri čemer so nekatera pravila bolj značilna za določena obdobja kot druga.



Slika 4: Uporaba različnih kompozicijskih pravil po obdobjih.

## 2.5 Kakšni so čustveni odzivi gledalcev na umetniška dela iz različnih obdobjih?

Osredotočili smo se tudi na analizo čustev in pogostosti besed v opisih slikarskih del, za to smo uporabili zbirko podatkov in modele iz projekta ArtEmis [17]. ArtEmis vključuje 439.000 čustvenih oznak in razlag, ki jih je več kot 6.000 ljudi pripisalo 81.000 umetniškim delom iz zbirke WikiArt. Cilj projekta je raziskati afektivno izkušnjo, ki jo sprožajo umetniška dela, ter razviti sisteme za generiranje opisov slik, ki izražajo čustvene odzive.


Pri analizi smo uporabili skripto iz repozitorija ArtEmis [18] za predprocesiranje podatkov, ki vključuje preverjanje črkovanja, popraviljanje, tokenizacijo in delitev podatkov na učno, validacijsko in testno množico. Nato smo podatke grupirali po umetniških delih, pri čemer smo označili obdobje in čustva, povezana z vsako sliko. Z uporabo knjižnice NLTK [19] (različica 3.9.1) smo odstranili neinformativne besede in besede pretvorili v njihovo osnovno obliko z lematizacijo, pri čemer smo obdržali le samostalnike, pridevnike in prislovna določila.

Dobljene podatke smo preoblikovali v seznam slovarjev, kjer smo za vsako unikatno besedo prešteli njeno pojavitev v opisih ter določili, v katero obdobje spada. Zaradi velikega števila besed (več kot 400.000) smo odstranili tiste, ki so se pojavile manj kot 800-krat. Besedi "painting" in "colors" smo odstranili zaradi pogoste uporabe v neinformativnih stavkih. Analiza čustvenih odzivov je razkrila, da so besede, kot je "contentment" (zadovoljstvo), med najpogostejšimi, kar kaže na pozitivne čustvene odzive na umetniška dela skozi različna obdobja. Poleg zadovoljstva so bila pogosta tudi čustva, kot so "awe" (spoštovanje in občudovanje izjemnega talenta in lepote), "amusement" (zabava) in "excitement" (vznemirjenje), kar nakazuje bogato čustveno doživljanje umetniških del.

Analiza opisov slikarskih del je pokazala zanimive vzorce v pogostosti uporabe različnih motivov skozi umetniška obdobja. Opazili smo, da je bila beseda "ženska" (woman) daleč najpogostejše uporabljena in prisotna v vseh analiziranih obdobjih. Za vizualizacijo teh podatkov smo uporabili oblak besed. Velikost besed v oblaku je sorazmerna z njihovo pogostostjo, kar omogoča hitro identifikacijo najpomembnejših terminov in tem, ki se pojavljajo v različnih umetniških obdobjih (slika 5, slika 6).



Slika 5: Najpogostejše besede v opisih slik iz baroka.



Slika 6: Najpogostejše besede v opisih slik iz impresionizma.

### 3 Zaključek

Naše ugotovitve ponujajo vpogled v vizualne in čustvene razlike med umetniškimi deli različnih obdobj. Računalniška orodja so nam omogočila, da smo izbrane likovnoteoretske koncepte lahko pregledali na veliki zbirki slik in o njihovi zastopanosti presojali skozi “oddaljeno gledanje”.

Pri nekaterih analizah smo prišli do nepričakovanih rezultatov. Pri analiziranju barvnih palet se dobljeni rezultati za določena obdobja niso skladali s pričakovanimi, prav tako bi pri vizualizaciji svetlosti in nasičenosti pričakovali več svetlejših slik za nekatera obdobja. Menimo, da rezultati odražajo na eni strani veliko raznolikost umetniških del znotraj posameznih obdobj in na drugi strani dejansko prisotnost del v zbirki WikiArt, ki ni v celoti skladna s kanonom, pri čemer je slednji izrazito omejen v primerjavi z naborom vseh del. Naša analiza barv na slikah je pokazala, da so pristopi “oddaljenega gledanja” slikarskih del zanimivi ne kot potrditev kanona, pač pa zato, ker razkrivajo velika področja v stilskem prostoru posameznega obdobja, ki jih kanon ne obravnava, čeprav so zasedena s številnimi manj reprezentativnimi deli. Na ta način lahko računalniško pregledovanje velikih digitaliziranih slikovnih zbirk usmeri pozornost na “spregledana” dela, ki so pravzaprav morda celo v večini, in odpira nova polja raziskovanja.

Pri posameznih analizah so seveda možne izboljšave in nadgradnje. Pri detekciji robov je možna izboljšava algoritma, ki bi zaznal poteze čopiča na sliki. Za analizo barv bi lahko uporabili tudi katere druge pristope, kot so analiza s histogramom, računanje barvnih momentov, uporaba modela Gaussove mešanice in drugih.

Pri analizi kompozicij smo naleteli na problem, saj se število ključnih območij razlikuje glede na kompozicijsko pravilo - pri pravilu tretjin so štiri presečišča, pri centralni kompoziciji pa le eno. To pomeni, da so kompozicije z več ključnimi območji zaznane z večjo verjetnostjo. Poskusili smo kompenzirati tako, da smo zmanjšali velikost območij zaznave, če jih je bilo več, in velikost povečali, če jih je bilo manj. Kljub temu bi bila zaznava kompozicij bolj natančna z uporabo nekaterih drugih pristopov, npr. uporabo učne množice za učenje modela za klasifikacijo slik.

Vizualne analize likovnih del s pomočjo algoritmov računalniškega vida so uporaben pedagoški pripomoček

za muzeje, ki lahko s tovrstnimi sodobnimi in uporabniku prijaznimi interaktivnimi vmesniki svoje zbirke približajo obiskovalcem tudi z vidika likovne teorije, poleg običajnega podajanja ikonografskih in biografskih podatkov. Hitro pregledovanje velike zbirke digitaliziranih slik omogoča nove vpoglede in povezave v zbirki, onkraj kanonskih del, pri čemer vključuje tudi dela iz depojev, ki niso na ogled.

### 4 Zahvala

Avtorji se za podporo zahvaljujejo Javni agenciji za znanstvenoraziskovalno in inovacijsko dejavnost Republike Slovenije (Trajnostna digitalna hramba slovenske novomedijske umetnosti, J7-3158).

### Literatura

- [1] The Next Rembrandt. *The Next Rembrandt*. Accessed: 2024-09-06. 2023. URL: <https://www.nextrembrandt.com>.
- [2] Kathryn Brown. *The Routledge companion to digital humanities and art history*. Routledge, 2020.
- [3] David G Stork. “Computer vision and computer graphics analysis of paintings and drawings: An introduction to the literature”. V: *Computer Analysis of Images and Patterns: 13th International Conference, CAIP 2009, Münster, Germany, September 2-4, 2009. Proceedings 13*. Springer. 2009, str. 9–24.
- [4] VISART. *VISART 2018 Past Workshops*. Accessed: 2024-09-03. 2018. URL: <https://visarts.eu/past-workshops/2018/>.
- [5] Sebastian Korenič Tratnik in sod. “O tehno logiki likovnega stila: generiranje slik z umetno inteligenco na primeru izbranih slovenskih slikarjev.” V: *Art Words/Likovne besede* 124 (2023), str. 4–19.
- [6] Google Arts & Culture. *Google Arts & Culture*. Accessed: 2024-07-03. 2024. URL: <https://artsandculture.google.com/>.
- [7] Lev Manovich. *manovich.net*. Accessed: 2024-07-03. 2024. URL: <http://manovich.net/>.
- [8] Lev Manovich. *Cultural analytics*. Mit Press, 2020.
- [9] Wikiart, *Visual Art Encyclopedia*. <https://www.wikiart.org/en>. Accessed: 2024-07-03.
- [10] *Canny edge detection*. Accessed: 2024-07-02. URL: [https://docs.opencv.org/4.x/da/d22/tutorial\\_py\\_canny.html](https://docs.opencv.org/4.x/da/d22/tutorial_py_canny.html).
- [11] Adam Amram in Anat Ben-David. *image-color-analysis*. Accessed: 2024-06-27. 2016. URL: <https://github.com/omilab/image-color-analysis>.
- [12] A. Ben-David, A. Amram in R. Bekkerman. “The Colors of the National Web: Visual Data Analysis of the Historical Yugoslav Web Domain”. V: *International Journal on Digital Libraries* (2018).



- [13] Lev Manovich in sod. *ImagePlot*. Accessed: 2024-07-02. 2017. URL: <https://github.com/culturevis/imageplot>.
- [14] Lev Manovich. “Data Science and Digital Art History”. V: *International Journal for Digital Art History* 1 (jun. 2015). DOI: 10.11588/dah.2015.1.21631. URL: <https://journals.ub.uni-heidelberg.de/index.php/dah/article/view/21631>.
- [15] OpenCV. *Saliency API*. Accessed: 2024-07-03. 2024. URL: [https://docs.opencv.org/4.x/d8/d65/group\\_\\_saliency.html](https://docs.opencv.org/4.x/d8/d65/group__saliency.html).
- [16] scikit-image. *Skimage Transform: Probabilistic Hough Line*. Accessed: 2024-07-03. 2024. URL: [https://scikit-image.org/docs/stable/api/skimage.transform.html#skimage.transform.probabilistic\\_hough\\_line](https://scikit-image.org/docs/stable/api/skimage.transform.html#skimage.transform.probabilistic_hough_line).
- [17] Panos Achlioptas in sod. “ArtEmis: Affective Language for Visual Art”. V: *CoRR* abs/2101.07396 (2021).
- [18] *ArtEmis GitHub Repository*. <https://github.com/optas/artemis>. Accessed: 2024-07-02.
- [19] Steven Bird, Ewan Klein in Edward Loper. *Natural language processing with Python: analyzing text with the natural language toolkit*. O’Reilly Media, Inc., 2009.